

2025 度卒業論文
量子アニーリングを用いた
ニューラルネットワーク構造最適化

東海大学
情報理工学部情報科学科
牧野研究室
指導教員 牧野浩典教授
並木大悟

学籍番号 2CDI1205
提出日 2026 年 2 月 4 日

第 1 章

序論

1,1 研究背景

1.1.1 計算資源の枯渇

近年の深層学習モデルの大規模化に伴い、学習時に必要となる計算コストやメモリ使用量の増大が大きな問題になっている。このような背景において、限られた計算資源のもと、効率的で高性能なニューラルネットワークモデルを構築する手法が求められている。

1.1.2 量子アニーリング

量子アニーリング（Quantum Annealing : QA）は、量子力学的効果を活用して最適解を探索する計算手法の一つである。この手法は 1980 年代後半に日本の研究者によって提案され、その後、2010 年代に入って専用の計算機が実用化されたことで注目を集めるようになった。一般に、組合せ最適化問題は問題規模の増大に伴い探索空間が爆発的に拡大し、古典計算機では解くことが困難な NP 困難問題となることが多い。量子アニーリングは、このような問題に対して有効な解法として知られている。具体的には、解きたい最適化問題をスピン変数で表現されるエネルギー関数へと変換し、その基底状態を探索することで最適解を得る。量子揺らぎを利用して局所解からの脱出を促しながら探索を行う点が、この手法の特徴である。

1.2 研究目的

本研究の目的は、量子アニーリングを用いてニューラルネットワーク構造最適化（Neural Architecture Search : NAS）を行い、モデル設計の効率化を図ることである。従来の NAS 手法では、候補となるネットワーク構造ごとに学習や評価を繰り返す必要があり、計算コストや探索時間が大きな課題となっている。特に、探索空間が大規模になるにつれて、効率的な最適化は困難となる。

そこで本研究では、ネットワーク構造の最適化問題を組合せ最適化問題として定式化し、量子アニーリングを用いて高速に良好な構造を探索する手法を検討する。これにより、従来手法と比較して探索に要する計算資源を削減しつつ、高性能なネットワーク構造を効率的に獲得することを目指す。

目次

第 1 章.....	1
序論.....	1
1.1 研究背景.....	1
1.1.1 計算資源の枯渇.....	1
1.1.2 量子アニーリング.....	1
1.2 研究目的.....	2
第 2 章.....	5
ゼロショット NAS と NASWOT.....	5
2.1 Neural Architecture Search (NAS) の概要.....	5
2.2 ゼロショット NAS の基本概念.....	5
2.3 NASWOT.....	6
2.3.1 NASWOT の原理.....	6
2.3.2 活性化パターンとカーネル行列.....	6
2.3.3 NASWOT スコアの定義.....	7
2.4 NASWOT の課題.....	7
第 3 章.....	9
量子アニーリング.....	9
3.1 組合せ最適化問題.....	9
3.2 イジング模型と QUBO.....	9
3.2.1 イジング模型.....	9
3.2.2 QUBO 定式化.....	10
3.3 量子アニーリングの原理.....	10
3.3.1 量子アニーリングの仕組み.....	10
3.3.2 探索特性と制約.....	11
第 4 章.....	12
提案手法.....	12
4.1 問題設定.....	12
4.1.1 ネットワーク構造の二値表現.....	12
4.2 NASWOT スコアの近似.....	12
4.2.1 サンプリングによる学習データ構築.....	13
4.2.2 LASSO 回帰による二次近似.....	13

4.3 QUBO 定式化と最適化	14
4.3.1 目的関数の構築	14
4.3.2 段階的最適化手法	15
第 5 章.....	16
実験設定	16
5.1 使用ベンチマーク	16
5.1.1 NAS-Bench-201	16
5.1.2 NAS-Bench-301	17
5.2 実験条件.....	17
5.3 評価指標.....	17
第 6 章.....	19
実験結果と考察	19
6.1 NASWOT と分類精度の相関	19
6.2 最適化過程の結果	20
6.3 考察	21
謝辞.....	22
参考文献	23

第 2 章

ゼロショット NAS と NASWOT

2.1 Neural Architecture Search (NAS) の概要

Neural Architecture Search (NAS) は、ニューラルネットワークの構造を自動的に探索・最適化する手法であり、深層学習分野において広く研究されている。従来、ネットワーク構造の設計は人手による試行錯誤に依存していたが、モデルの複雑化に伴い、その設計コストは増大している。NAS では、探索アルゴリズムを用いて候補となる構造を生成・評価し、高性能なネットワークを効率的に発見することを目的とする。一般に、NAS は探索空間、探索戦略、評価手法の三要素から構成される。しかし、多数の構造を学習・評価する必要があるため、計算コストが大きいという課題がある。近年では、この問題に対処するため、学習を伴わずに構造を評価する手法など、効率化を目的とした研究も進められている。

2.2 ゼロショット NAS の基本概念

ゼロショット NAS (Zero-shot NAS) は、ニューラルネットワークの学習を行わずに構造の性能を評価する NAS 手法であり、探索コストの大幅な削減を目的として提案されている。従来の NAS では、各候補構造に対して学習と検証を繰り返す必要があり、計算時間や計算資源の面で大きな負担となっていた。ゼロショット NAS では、ランダム初期化された重みやネットワークの構造的特徴を用いてスコアを算出し、その値に基づいて構造の優劣を評価する。これにより、学習を伴わずに多数の構造を高速に比較することが可能となる。代表的な手法として、勾配情報や活性化の統計量を用いた評価指標などが提案されており、計算効率と性能の両立を目指した研究が進められている。

2.3 NASWOT

2.3.1 NASWOT の原理

NASWOT (Neural Architecture Search Without Training) は、ネットワークの学習を行うことなく、その構造の性能を評価するゼロショット NAS 手法の一つである。NASWOT は、ネットワーク内部の活性化パターンに基づいてスコアを算出し、その値によって構造の優劣を評価する点に特徴がある。一般に、異なる入力に対して多様な表現を生成できるネットワーク構造ほど、高い表現能力を持つと考えられる。NASWOT では、この表現多様性を指標として構造を評価することで、学習を伴わずに有望なネットワーク構造を効率的に選択することを目的としている。

2.3.2 活性化パターンとカーネル行列

NASWOT では、ニューラルネットワークにランダム初期化された重みを与え、入力データを通過させた際の各ユニットの活性化パターンを用いて評価を行う。特に ReLU 活性化関数の出力に着目し、各ユニットの出力が正であるかどうかを判定することで、活性化状態を二値行列として表現する。具体的には、入力サンプルごとにユニットが活性化している場合を 1、そうでない場合を 0 とする二値行列 X を構成する。この行列は、入力データに対するネットワークの活性化構造を表していると解釈できる。この二値行列を用いて、入力サンプル間の類似度を表すカーネル行列を定義し、その対数行列式(log-determinant)を NASWOT スコアとして用いる。カーネル行列の対数行列式は行列のランクや多様性を反映する量であり、その値が大きいほど、ネットワークが入力データをより多様に区別して表現していると解釈できる。

2.3.3 NASWOT スコアの定義

NASWOT では、前節で定義した活性化パターンの二値行列を用いてカーネル行列を構成し、その対数行列式 (log-determinant) をスコアとしてネットワーク構造の評価を行う。ここで、入力サンプル数を N 、ネットワークの全ユニット数を M とし、活性化パターンの二値行列を $X \in \{0,1\}^{N \times M}$ と定義する。このとき、NASWOT で用いられるカーネル行列 $K \in \mathbb{R}^{N \times N}$ は次式で与えられる。

$$K = XX^T + (1 - X)(1 - X)^T \quad (2.1)$$

ここで、 X は各入力に対するユニットの活性化状態を表し、 $1 - X$ は非活性化状態を表す行列である。このカーネル行列は、入力サンプル間で活性化パターンがどの程度一致しているかを測る類似度行列として解釈できる。

NASWOT スコアは、このカーネル行列の対数行列式によって定義される。

$$\text{NASWOT スコア} = \log \det (K) \quad (2.2)$$

対数行列式は行列のランクや多様性を反映する量であり、その値が大きいほど、入力サンプルに対して多様な活性化パターンを生成できるネットワーク構造であると考えられる。したがって、NASWOT では、このスコアが大きい構造ほど高い表現能力を持つと評価される。

2.4 NASWOT の課題

NASWOT は、学習を行わずにネットワーク構造を評価できる点で非常に有効なゼロショット NAS 手法であるが、いくつかの課題も存在する。まず、NASWOT スコアの計算にはカーネル行列の対数行列式を求める必要があり、入力サンプル数が増加すると計算コストが大きくなる。特に、カーネル行列のサイズは入力サンプル数に依存して増大するため、大規模データセットに対しては計算が困難となる可能性がある。また、log-determinant の計算は数値的に不安定となる場合があり、行列が特異に近い場合にはスコアが適切に算出されないことがある。

さらに、NASWOT は活性化パターンの多様性に基づく指標であるため、必ずしも最終的なタスク性能を完全に反映できるとは限らない。以上の点から、NASWOT は効率的な評価手法である一方で、計算コストや数値安定性の面で改善の余地があり、より効率的な最適化手法の導入が求められている。

第3章

量子アニーリング

3.1 組合せ最適化問題

組合せ最適化問題とは、離散的な選択肢の組合せの中から、ある評価基準に基づいて最適な解を求める問題である。代表的な例として、巡回セールスマン問題やナップサック問題などが挙げられ、多くの実用的な問題がこの枠組みに含まれる。一般に、組合せ最適化問題は問題規模の増大に伴い探索空間が指数関数的に増加し、全探索による解法は現実的でなくなる。このような問題の多くは NP 困難であり、効率的に最適解を求めることが困難である。量子アニーリングは、このような組合せ最適化問題を解くための計算手法の一つであり、問題をエネルギー最小化問題として定式化することで解探索を行う。目的関数をスピン変数で表されるエネルギー関数に変換し、その基底状態を探索することで、最適解を得ることが可能となる。

3.2 イジング模型と QUBO

3.2.1 イジング模型

イジング模型 (Ising model) は、磁性体の振る舞いを表現するために提案された統計物理モデルであり、量子アニーリングにおいて基礎となる数理モデルの一つである。イジング模型では、各変数はスピンと呼ばれる二値変数として表され、その値は $s_i \in \{-1, +1\}$ を取る。

イジング模型のエネルギー関数は、次式で定義される。

$$E(\mathbf{s}) = \sum_i h_i s_i + \sum_{i < j} J_{ij} s_i s_j \quad (3.1)$$

ここで、 h_i は各スピンに作用する外部磁場、 J_{ij} はスピン間の相互作用係数を表す。エネルギー関数の値が小さいほど安定した状態であり、基底状態はエネルギーが最小となるスピン配置に対応する。

量子アニーリングでは、解きたい組合せ最適化問題をこのエネルギー関数の最小化問題として表現し、スピン配置を探索することで最適解を求める。このため、イジング模型は量子アニーリングにおける問題表現の基本形式として広く用いられている。

3.2.2 QUBO 定式化

QUBO (Quadratic Unconstrained Binary Optimization) は、二値変数の二次関数を最小化する最適化問題の形式であり、量子アニーリングマシンで直接扱うことが可能な問題表現の一つである。QUBO では、各変数は $x_i \in \{0,1\}$ を取る二値変数として表され、目的関数は次式で与えられる。

$$E(\mathbf{x}) = \sum_i Q_{ii} x_i + \sum_{i < j} Q_{ij} x_i x_j \quad (3.2)$$

ここで、 Q_{ii} は各変数に対応する一次項の係数、 Q_{ij} は変数間の相互作用を表す二次項の係数である。このエネルギー関数を最小化する二値変数の組合せが、最適解に対応する。QUBO 形式は制約条件を持たない最適化問題として表現されているが、制約をペナルティ項として目的関数に組み込むことで、制約付き最適化問題も扱うことが可能である。また、QUBO 形式はイジング模型と等価な表現であり、変数変換 $s_i = 2x_i - 1$ を用いることで、イジング形式と相互に変換できる。このように、QUBO 定式化は組合せ最適化問題を量子アニーリングで解くための標準的な問題表現であり、実装面においても扱いやすい形式として広く利用されている。

3.3 量子アニーリングの原理

3.3.1 量子アニーリングの仕組み

量子アニーリングは、量子力学的な性質を利用して最適解を探索する最適化手法であり、エネルギー最小化問題として定式化された組合せ最適化問題を解くために用いられる。古典的なシミュレーテッドアニーリングでは熱揺らぎを利用して局所解からの脱出を行うのに対し、量子アニーリングでは量子揺らぎを利用して探索を行う点が特徴である。量子アニーリングでは、初期状態として全ての状態の重ね合わせを持つ簡単なハミルトニアンを設定し、時間とともに問題ハミルトニアンへと徐々に変化させる。この過程において、システムは基底状態を保ったまま時間発展することが期待され、最終的に問題ハミルトニアンの基底状態、すなわち最適解へと到達する。この時間発展は、量子力学における断熱定理に基づいており、十分にゆっくりとハミルトニアンを変化させることで、高い確率で最適解を得ることが可能となる。量子揺らぎによるトンネル効果により、古典的手法では脱出が困難な局所最適解からも効率的に探索できる点が、量子アニーリングの大きな利点である。

3.3.2 探索特性と制約

量子アニーリングの探索特性として、量子揺らぎによるトンネル効果を利用することで、古典的な最適化手法では脱出が困難な局所最適解からも効率的に探索できる点が挙げられる。これにより、エネルギー障壁の高い問題に対しても、解空間を広く探索することが可能となる。また、多数の状態を重ね合わせとして同時に扱うことができるため、大規模な探索空間に対しても並列的な探索が期待されている。一方で、量子アニーリングにはいくつかの制約も存在する。まず、ハミルトニアンの時間変化が十分に緩やかでない場合、基底状態から励起状態へ遷移する可能性があり、最適解に到達できないことがある。また、実際の量子アニーリングマシンではノイズやデコヒーレンスの影響を受けるため、理論通りの断熱進化が保証されない場合も多い。さらに、問題サイズや結合構造にハードウェア上の制約が存在し、全ての最適化問題をそのまま実装できるわけでは

ない。このように、量子アニーリングは強力な探索能力を持つ一方で、物理的および実装上の制約も併せ持つ手法であり、問題の定式化やパラメータ設計が解の品質に大きく影響する。

第 4 章

提案手法

4.1 問題設定

4.1.1 ネットワーク構造の二値表現

本研究では、ニューラルネットワーク構造最適化問題を組合せ最適化問題として定式化し、量子アニーリングによって解くことを目的とする。そのため、ネットワーク構造を二値変数によって表現する。具体的には、ネットワーク中の各エッジにおける演算の選択を二値変数で表し、ある演算が選択される場合を 1、選択されない場合を 0 とする。これにより、ネットワーク構造全体は二値ベクトルとして表現され、各要素は構造中の演算の有無に対応する。このような二値表現を用いることで、ネットワーク構造の探索問題を QUBO 形式の最適化問題として定式化することが可能となる。すなわち、二値変数の組合せを最適化することで、最も評価指標の高いネットワーク構造を探索する枠組みを構築する。

4.2 NASWOT スコアの近似

NASWOT スコアはネットワーク構造の評価指標として有効であるが、その計算には対数行列式の演算が含まれるため、構造数が増加すると計算コストが大きくなる。また、量子アニーリングでは高次元の連続関数を直接扱うことができず、二次形式の離散最適化問題として定式化する必要があるという制約が存在する。そこで本研究では、NASWOT スコアを直接最適化するのではなく、二値変数で表現されたネットワーク構造を入力とし、NASWOT スコアを出力とする近似関数を学習することで、効率的かつ量子アニーリングに適した形式で最適化を行う手法を提案する。

4.2.1 サンプリングによる学習データ構築

近似モデルを学習するためには、ネットワーク構造と対応する NASWOT スコアの組からなる学習データが必要となる。本研究では、探索空間からネットワーク構造をランダムにサンプリングし、それぞれの構造に対して NASWOT スコアを計算することで学習データを構築する。具体的には、各エッジにおける演算の選択をランダムに決定することで複数の構造を生成し、それらに対して NASWOT スコアを算出する。このようにして得られた二値構造ベクトルと NASWOT スコアの対応関係を、近似モデルの教師データとして用いる。この手法により、探索空間全体を網羅的に評価することなく、限られたサンプルから NASWOT スコアの傾向を学習することが可能となり、後続の最適化処理を効率的に行うことができる。

4.2.2 LASSO 回帰による二次近似

本研究では、NASWOT スコアを二値変数で表現されたネットワーク構造の関数として近似するため、二次関数モデルを用いる。具体的には、ネットワーク構造を表す二値ベクトル $\mathbf{x} \in \{0,1\}^n$ に対して、NASWOT スコア $f(\mathbf{x})$ を次式のような二次関数で近似する。

$$\hat{f}(\mathbf{x}) = \mathbf{x}^T A \mathbf{x} + \mathbf{b}^T \mathbf{x} + c \quad (4.1)$$

ここで、 A は二次項の係数行列、 $\mathbf{b}$ は一次項の係数ベクトル、 c は定数項を表す。この形式は QUBO と同型であり、量子アニーリングに直接適用可能な点が特徴である。

係数 $A, \mathbf{b}, c$ の推定には LASSO 回帰を用いる。LASSO 回帰は L_1 正則化を導入した線形回帰手法であり、次式で与えられる目的関数を最小化することで係数を求める。

$$\min_{\theta} \frac{1}{2M} \| \Phi \theta - \mathbf{y} \|_2^2 + \lambda \| \theta \|_1 \quad (4.2)$$

ここで、 Φ は二次特徴量を含む設計行列、 $\mathbf{y}$ は NASWOT スコア、 θ はモデルパラメータ、 λ は正則化係数である。LASSO 回帰を用いることで、重要な係数のみが非零となり、モデルのスパース化が促進される。これにより、高次元な探索空間に対しても過学習を抑えつつ、効率的に NASWOT スコアの近似モデルを構築することが可能となる。

4.3 QUBO 定式化と最適化

前節までで構築した NASWOT スコアの二次近似モデルを用いて、本研究ではネットワーク構造最適化問題を QUBO 形式として定式化し、量子アニーリングによる最適化を行う。これにより、NASWOT スコアが最大となるネットワーク構造を、組合せ最適化問題として直接求めることが可能となる。

4.3.1 目的関数の構築

4.2 節で得られた二次近似モデルは、ネットワーク構造を表す二値変数 $\mathbf{x} \in \{0,1\}^n$ に対して、NASWOT スコアを次式で近似している。

$$\hat{f}(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c \quad (4.3)$$

この近似モデルは QUBO 形式と同型であるため、本研究ではこの式をそのまま目的関数として用いる。ただし、量子アニーリングではエネルギー最小化問題を解くため、NASWOT スコアの最大化問題は符号を反転させることで最小化問題に変換する。

$$E(\mathbf{x}) = -\hat{f}(\mathbf{x}) \quad (4.4)$$

このエネルギー関数を最小化する二値変数の組合せが、NASWOT スコアを最大化するネットワーク構造に対応する。したがって、本研究ではこの QUBO 問題を量子アニーリングに入力し、最適な構造を探索する。

4.3.2 段階的最適化手法

ネットワーク構造の探索空間は非常に大規模であり、全ての変数を同時に最適化することは計算的に困難である。さらに、量子アニーリングマシンでは同時に扱えるビット数にハードウェア上の制約が存在するため、大規模な QUBO 問題をそのまま入力することは現実的ではない。そこで本研究では、探索空間を段階的に縮小しながら最適化を行う段階的最適化手法を採用する。具体的には、まず一部のエッジや演算のみを対象とした小規模な QUBO 問題を解き、有望な構造候補を抽出する。その後、残りの変数を追加して再度最適化を行うことで、探索範囲を徐々に拡張していく。

本研究では、量子アニーリングの計算は実機ではなく、自作の物理モデルに基づく量子アニーリングシミュレーションを用いて実施しているが、実機と同様に扱えるビット数には制約が存在する。そのため、問題サイズを段階的に増加させることで、計算負荷およびビット数制約の両方を考慮しつつ、効率的な探索を実現する。この手法により、全探索が困難な大規模探索空間に対しても、量子アニーリングを用いて現実的な計算時間で高品質なネットワーク構造を得ることが可能となる。

第 5 章

実験設定

5.1 使用ベンチマーク

本研究では、提案手法の有効性を検証するために、既存のニューラルアーキテクチャ探索ベンチマークを用いて実験を行う。NAS ベンチマークは、あらかじめ多数のネットワーク構造に対する学習結果や評価精度が計算されており、異なる手法間で公平な比較が可能である点に特徴がある。本研究では、代表的なセルベースの NAS ベンチマークである NAS-Bench-201 および NAS-Bench-301 を使用し、それぞれ異なる探索空間における提案手法の性能を評価する。

5.1.1 NAS-Bench-201

NAS-Bench-201 は、比較的小規模な探索空間を持つ NAS ベンチマークであり、セル構造に基づいた全 15625 通りのネットワーク構造が事前に評価されている。各セルは 4 つのノードと 6 本のエッジから構成され(図 1)、各エッジには複数の候補演算(表 1)が定義されている。このベンチマークでは、CIFAR-10、CIFAR-100、ImageNet-16-120 などの複数のデータセットに対する分類精度が提供されており、探索結果を真の性能と直接比較することが可能である。探索空間が有限かつ全列挙されているため、提案手法の基本的な妥当性や性能傾向を検証するのに適したベンチマークである。




図 1 :NAS-Bench-201 のセル構造

演算候補(201)
接続なし
スキップ接続
1×1 畳み込み
3×3 畳み込み
3×3 平均プーリング

表 1 :NAS-Bench201 の演算候補

5.1.2 NAS-Bench-301

NAS-Bench-301 は、DARTS に基づく大規模な探索空間を対象とした NAS ベンチマークであり、正規セルと縮小セルの 2 種類のセル構造から構成される。各セルは複数のノードとエッジを含み、各エッジで選択可能な演算の種類も多いため、探索空間は非常に大規模である。NAS-Bench-301 では、全探索が困難な大規模探索空間に対して、代理モデル（サロゲートモデル）を用いて各構造の性能を予測する形式が採用されている。これにより、実際に全構造を学習させることなく、探索アルゴリズムの性能評価が可能となっている。本研究では、このベンチマークを用いて、提案手法が大規模探索空間に対しても有効に機能するかを検証する。

5.2 実験条件

本研究では、提案手法の有効性を検証するために、NAS-Bench-201 および NAS-Bench-301 を用いて実験を行った。各ベンチマークに対して、探索空間からネットワーク構造をランダムにサンプリングし、それぞれに対応する NASWOT スコアを計算することで学習データを構築した。近似モデルの学習には LASSO 回帰を用い、正則化係数 λ は交差検証により決定した。二次近似モデルの入力はネットワーク構造の二値ベクトルとし、出力は対応する NASWOT スコアとした。構築した近似モデルに基づいて QUBO 問題を定式化し、量子アニーリングによる最適化を行った。本研究では、実機の量子アニーリングマシンや OpenJij ではなく、物理モデルに基づく量子アニーリングシミュレーションを用いて実施した。各最適化は複数回実行し、得られた解の中から最も評価値の高い構造を最終的な探索結果とした。評価においては、提案手法によって得られたネットワーク構造の真の分類精度をベンチマークにより取得し、NASWOT スコアおよび既存手法との比較を行った。

5.3 評価指標

本研究では、提案手法によって得られたネットワーク構造の有効性を評価するために、複数の評価指標を用いる。主に、NASWOT スコアと実際の分類精度との関係、および提案手法によって選択された構造の性能に着目して評価を行う。

まず、評価指標の一つとして、NASWOT スコアと真の分類精度との相関係数を用いる。相関係数には、スピアマンの順位相関係数およびケンドールの順位相関係数を用い、スコアの順位と実際の性能順位との一致度を評価する。これにより、NASWOT スコアが性能指標としてどの程度妥当であるかを定量的に確認する。次に、提案手法によって最終的に得られたネットワーク構造の分類精度を評価指標とする。NAS-Bench-201 および NAS-Bench-301 において提供されている真の精度情報を用い、ランダム探索や既存の NAS 手法によって得られた構造と比較することで、提案手法の有効性を検証する。

第 6 章

実験結果と考察

6.1 NASWOT と分類精度の相関

本節では、NASWOT スコアと実際の分類精度との関係について検証を行う。NAS-Bench-201 および NAS-Bench-301 の探索空間から複数のネットワーク構造をサンプリングし、それぞれに対して NASWOT スコアと真の分類精度を算出した。

図 2、図 3 に、各ネットワーク構造における NASWOT スコアと分類精度の散布図を示す。横軸は分類精度、縦軸は NASWOT スコアを表している。この図より、NASWOT スコアと分類精度の間には正の相関関係が見られることが確認できる。

定量的な評価として、スピアマンの順位相関係数およびケンドールの順位相関係数を算出した。その結果、NAS-Bench-201 ではスピアマン相関係数が 0.796、ケンドール相関係数が 0.610 となり、NAS-Bench-301 においても $\rho=0.612$ 、 $\tau=0.433$ と同様に正の相関が確認された。これらの結果は、NASWOT スコアがネットワーク構造の性能をある程度反映した指標であることを示している。以上より、NASWOT は学習を伴わずに構造性能を評価可能な指標として有効であり、ネットワーク構造最適化における評価関数として妥当性を有すると考えられる。




図 2 : NAS-Bench-201 における

NASWOT スコアと分類精度の順位相関




図 3 : NAS-Bench-301 における

NASWOT スコアと分類精度の順位相関

6.2 最適化過程の結果

本節では、提案手法に基づいて量子アニーリングによるネットワーク構造最適化を行った際の最適化過程について示す。表 2 に、各最適化ステップにおける NASWOT スコアおよび分類精度を示す。

NAS-Bench-201 においては、初期ステップでは NASWOT スコアおよび分類精度が著しく低い構造が得られているが、2 回目以降の最適化では高いスコア帯に遷移しており、その後は安定して高い NASWOT スコアおよび分類精度を示していることが分かる。

一方、NAS-Bench-301 においては、最適化の進行に伴って NASWOT スコアおよび分類精度が概ね単調に増加しており、段階的最適化によってより高性能な構造が徐々に選択されていることが確認できる。また、最適化によって得られたネットワーク構造の分類精度を比較した結果、ランダムに選択した構造と比べて、平均的に高い精度を示す傾向が確認された。これは、提案手法が NASWOT スコアを指標として有効に機能し、性能の高い構造を効率的に探索できていることを示している。

以上の結果より、量子アニーリングを用いた最適化過程において、NASWOT スコアの改善と分類精度の向上が同時に確認され、提案手法の有効性が示された。

NAS-Bench201	分類精度	NASWOT	NAS-Bench301	分類精度	NASWOT
run=0	73.74	1262.455	run=0	92.41	1690.24
run=1	92.5	1597.438	run=1	93.05	1716.44
run=2	92.41	1681.174	run=2	93.08	1720.71
run=3	92.71	1746.982	run=3	93.25	1728.59
run=4	92.71	1743.817	run=4	93.89	1755.02
run=5	92.71	1749.637	run=5	93.9	1755.43
run=6	92.4	1747.514	run=6	93.79	1765.22
run=7	92.4	1747.996	run=7	93.81	1769.2
run=8	92.4	1746.367	run=8	93.85	1770.37
run=9	89.37	1745.913	run=9	93.94	1769.16
run=10	89.3	1723.67	run=10	93.85	1767.73
run=11	89.5	1693.99	run=11	93.94	1774.1
run=12	93.1	1721.899	run=12	93.94	1774.53
run=13	93.13	1746.392	run=13	94.06	1773.72
run=14	92.83	1745.441	run=14	94.04	1774.45

表 2 : NAS-Bench-201 と NAS-Bench-301 のそれぞれの各 run に
おける最終構造の予測精度および NASWOT スコア

6.3 考察

本研究では、量子アニーリングを用いたニューラルネットワーク構造最適化手法を提案し、NAS-Bench-201 および NAS-Bench-301 を用いてその有効性を検証した。その結果、NASWOT スコアと分類精度の間に正の相関が確認され、NASWOT が構造性能を評価する指標として一定の妥当性を持つことが示された。さらに、提案手法による最適化過程において、NASWOT スコアの増加に伴い分類精度も向上する傾向が見られ、量子アニーリングを用いた探索が有効に機能していることが確認された。

この結果は、NASWOT スコアを近似した二次モデルが、ネットワーク構造と性能の関係にある程度適切に捉えていることを示唆している。特に、LASSO 回帰によるスパースな二次近似を用いることで、高次元な探索空間においても過学習を抑えつつ、効率的な最適化が可能となった点は本研究の重要な成果であると考えられる。

一方で、本研究にはいくつかの課題も残されている。まず、NASWOT 自体が活性化パターンの多様性に基づく指標であるため、必ずしも最終的な分類精度を完全に反映するものではない。また、NASWOT スコアの近似精度はサンプリング数や特徴量設計に依存しており、近似誤差が最適化結果に影響を与える可能性がある。さらに、本研究では量子アニーリングシミュレータを用いており、実機での動作やノイズの影響については考慮できていない。

今後の課題としては、より高精度な評価指標の導入や、高次の近似モデルの検討、実機の量子アニーリングマシンを用いた実験などが挙げられる。また、他のゼロショット指標との組み合わせやマルチ目的最適化への拡張により、より実用的なニューラルネットワーク構造最適化手法への発展が期待される。

謝辞

本研究の遂行にあたり、多くのご指導を賜りました牧野浩典教授に心より感謝申し上げます。研究内容に関する助言を通じて、本研究を進める上で多くの示唆をいただきました。

また、研究室の皆様には日頃より有益な議論や助言をいただき、研究を円滑に進めることができました。ここに深く感謝いたします。

さらに、研究活動を支えてくれた家族や友人にも感謝申し上げます。皆様の支えがあったからこそ、本研究に取り組むことができました。

参考文献

[1] J. Mellor et al., “Neural Architecture Search without Training,” ICML, 2021.

[2] 西森秀稔、大関真之：「量子アニーリングの基礎」、共立出版（2020）

[3] AI-SCHOLAR：「NASWOT：学習なしでニューラルネットワーク構造を評価する手法」, <https://ai-scholar.tech/articles/nas/NASWOT>

[4] Qiita：「Lasso 回帰の理論と実装」,
https://qiita.com/miya_ppp/items/cebe1e75192211a00d9f