

量子アニーリングによるニューラルネットワークの構造最適化

研究生：2CDI1205 並木大悟

指導教員：牧野浩典 教授

1, 序論

近年の深層学習モデルの大規模化に伴い、学習時に必要となる計算コストやメモリ使用量の増大が大きな問題になっている。このような背景において、限られた計算資源のもと、効率的で高性能なニューラルネットワークモデルを構築する手法が求められている。そのアプローチの一つとして、ニューラルネットワークの構造の設計を経験則による試行錯誤ではなく、アルゴリズムによって自動的に探索・最適化する Neural Architecture Search (NAS) が用いられるようになった。

従来の NAS 手法では、多くの場合、候補となるネットワーク構造ごとに内部パラメータの学習を行い、精度を測る必要があり、計算コストが非常に大きいという問題がある。

そこで本研究では、パラメータ学習を行わずにネットワークの構造を評価するゼロショット指標である NASWOT と、組合せ最適化問題を効率的に解く手法である量子アニーリング (Quantum Annealing, QA) を合わせ、低計算コストで高性能なニューラルネットワーク構造を探索する手法を提案する。

2, ゼロショット NAS (NASWOT)

ゼロショット NAS とは、ネットワーク内部の重みを学習することなく、ネットワーク構造のみからその性能を評価する手法である。NASWOT はその代表的な手法であり、学習前のパラメータが設定されたネットワーク構造に対して入力データを一度だけ順伝播し、内部の活性化パターンに基づいて構造を評価する。具体的には、ネットワーク内の各 ReLU 活性化関数の入力が正か負かによって二値化を行い、異なる入力に対する活性化の一致度からカーネル行列

$$K = XX^T + (1 - X)(1 - X)^T \quad (2.1)$$

を構築する。ここでの X は内部の活性化を表す二値行列である。このカーネル行列の対数行列式

$$L = \log \det(K) \quad (2.2)$$

を NASWOT スコアとして用いることで、ネットワーク構造の表現力を評価する。NASWOT の基本的な考え方は、「異なる入力に対して多様な活性化パターンを生み出せる構造ほど、高い表現能力を持ち、学習後に高い分類精度を示す」という仮定に基づいている。

既存研究において、NASWOT は NAS-Bench 系ベンチマークにおいて実際の分類精度と正の順位相関を持つことが報告されており、学習を行わずに構造の良し悪しを判定できる指標であることが示されている[1]。

しかしながら、ニューラルネットワークの構造探索空間はそれでも十分大きいため、すべての構造に対して NASWOT を計算することは現実的ではなく、構造探索全体としては依然として計算時間が大きな課題となる。

3, 量子アニーリング(QA)

本研究では、ニューラルネットワーク構造最適化問題を解く手法として量子アニーリング (Quantum Annealing, QA) を用いる。量子アニーリングは、組合せ最適化問題を効率的に解くことを目的とした最適化手法で、最適化したい目的関数が二次以下の形式で表現できる場合、広い探索空間を持つ問題に対しても、計算コストを抑えながら有望な解を探索できる。

本研究では、NASWOT スコアを二次以下の目的関数として近似し、量子アニーリングによって最適化することで、全探索が困難な構造探索問題を効率的に解くことを目指す。

4, 実験設定

本研究では、NAS-Bench-201 および NAS-Bench-301 を用いて実験を行う。

NAS-Bench-201 は、探索空間が比較的小さく、すべてのネットワーク構造に対する学習後の分類精度があらかじめ与えられているベンチマークである。そのため、探索手法の挙動や有効性を詳細に分析するのに適している。このベンチマークでは、4つのノードからなる有向非巡回グラフ構造のセル(図1)が用いられ、ノード間の接続関係は固定されている。NAS-Bench-201 ではこのセルを基本単位とし、何層も積み重ねたネットワーク構造を持つ。各エッジでは、表1の5種類の演算候補の中から1つが選択される。




表1: NAS-Bench201の演算候補

演算候補(201)
接続なし
スキップ接続
1×1 畳み込み
3×3 畳み込み
3×3 平均プーリング

図1: NAS-Bench-201のセル構造

一方、NAS-Bench-301 は、正規セルと縮小セルの2種類のセル構造から構成される大規模な探索空間を持つベンチマークである。NAS-Bench-201 と比べて、各セルはより多くのノードとエッジを含み、各エッジで選択可能な演算の種類も多いため、探索空間は著しく大きく、全探索は困難である。

5, 実験手順

NASWOT スコアは高次元の関数として定義されており、そのままでは量子アニーリングで直接最適化することができない。そこで本研究では、LASSO 回帰を用いて NASWOT スコアを二次の関数として近似して行う。

具体的には、

- ① 各エッジにおける演算の選択を二値変数 x_{ij} として表現する。(演算 j をエッジ i に割り当てる場合を 1、割り当てない場合を 0 とする)

- ② 複数の演算の組み合わせをサンプリングし、それぞれの組み合わせに対して NASWOT スコアを計算する。これにより、演算選択 (x_{ij}) と対応する NASWOT スコアの組からなる学習データを構築する。
- ③ 得られた学習データを用いて、LASSO 回帰により NASWOT スコアを二値変数 x_{ij} に関する二次以下の関数として近似する。
- ④ 得られた近似モデルを目的関数として QUBO に定式化し、量子アニーリングによって最適化を行う。

ただし、量子アニーリングで扱える二値変数の数には制限があるため、最適化対象を一部取り出し、複数回に分けて段階的に最適化を行うことで、近似的に構造の探索を行う。

6, 実験結果と考察

図 2 および図 3 は、NASWOT スコアと分類精度との関係を示した相関図である。

図中の青の点はランダムにサンプリングされたネットワーク構造を表しており、×印は探索開始時の初期構造 (init)、★印は提案手法である量子アニーリングによって最終的に得られた構造 (QA last) を示している。

NAS-Bench-201 と NAS-Bench-301 のいずれの探索空間においても、ランダムサンプリングされた構造群において NASWOT スコアと分類精度の間には正の順位相関が確認できる。これは既存研究で報告されている結果と一致しており、NASWOT が学習を行わずに構造の良し悪しを評価できる有効な指標であることを示している。

また、図 2 および図 3 に示すように、QA によって選択された最終構造 (★) は、初期構造 (×) と比較して、より高い NASWOT スコアおよび高い分類精度を持つ領域へと移動していることが分かる。これは、提案手法が単にランダムに構造を探索するのではなく、NASWOT に基づく近似モデルと量子アニーリングを用いることで、分類性能の高い構造が得られやすい探索結果へと効果的に誘導できていることが示唆される。




図 2：NAS-Bench-201 における NASWOT スコアと分類精度の順位相関




図 3：NAS-Bench-301 における NASWOT スコアと分類精度の順位相関

201/301 とともに「未知エッジの候補を列挙して NASWOT を計算 → LASSO で 2 次近似 → QUBO 化 → QA で更新」を繰り返す点は共通だが、201 では実測精度を参照できる一方、301 ではサロゲート予測精度を用い、また 301 では接続（入力選択）を固定して演算選択のみを最適化している点が異なる。

表 2 は、NAS-Bench-201 および NAS-Bench-301 における最適化の各段階、すなわち run ごとに最適化された構造の分類精度および NASWOT スコアを示している。ここで、run=0 はそれぞれ図 2 と図 3 の×印に対応する初期構造、run=14 は★印に対応する最終構造を表す。表 2 より、run が進むにつれて NASWOT スコアが概ね一貫して増加しており、それに伴って分類精度も向上する傾向が確認できる。

一部の run において同一の結果が連続して現れているが、これは探索空間における局所的な最適解に到達したこと、あるいは選択されたエッジ・演算の組み合わせが既に安定していることに起因すると考えられる。

NAS-Bench201	分類精度	NASWOT	NAS-Bench301	分類精度	NASWOT
run=0	73.74	1262.455	run=0	92.41	1690.24
run=1	92.5	1597.438	run=1	93.05	1716.44
run=2	92.41	1681.174	run=2	93.08	1720.71
run=3	92.71	1746.982	run=3	93.25	1728.59
run=4	92.71	1743.817	run=4	93.89	1755.02
run=5	92.71	1749.637	run=5	93.9	1755.43
run=6	92.4	1747.514	run=6	93.79	1765.22
run=7	92.4	1747.996	run=7	93.81	1769.2
run=8	92.4	1746.367	run=8	93.85	1770.37
run=9	89.37	1745.913	run=9	93.94	1769.16
run=10	89.3	1723.67	run=10	93.85	1767.73
run=11	89.5	1693.99	run=11	93.94	1774.1
run=12	93.1	1721.899	run=12	93.94	1774.53
run=13	93.13	1746.392	run=13	94.06	1773.72
run=14	92.83	1745.441	run=14	94.04	1774.45

表 2：NAS-Bench-201 と NAS-Bench-301 のそれぞれの各 run における最終構造の予測精度および NASWOT スコア

以上の表および図に示した結果から、提案手法は NASWOT を用いて構造の良し悪しを評価し、その関係を近似した QUBO を量子アニーリングによって最適化することで、反復的により高性能な構造へと更新できることが確認された。

特に、run が進むにつれて NASWOT スコアが一貫して向上し、それに伴って分類精度（または予測精度）も改善している点は、提案手法が安定した探索挙動を示していることを示唆している。

7, 参考文献

- [1] J. Mellor et al., “Neural Architecture Search without Training,” ICML, 2021.
- [2] 西森秀稔、大関真之：「量子アニーリングの基礎」、共立出版（2020）